MÃ ĐỀ DEV-01 · NHÓM P-126 · DEMO DAY

VIVI Cabin Copilot

Trợ lý giọng nói trên xe VinFast — **đa phương thức** (voice, text, cảm ứng), **vẫn hoạt động khi mạng kém**, và không để mô hình ngôn ngữ tự quyết định thao tác trên xe.

Đinh Văn Hùng · trưởng nhóm
Nguyễn Thanh Phong
Nguyễn Minh Dương
Hoàng Trung Khải

PAIN POINT

Lái xe là lúc tài xế ít có thể thao tác nhất

01 · HAI TAY TRÊN VÔ LĂNG, MẮT TRÊN ĐƯỜNG

Mỗi lần với tay chỉnh điều hòa, mở nhạc, tìm điểm đến là một lần rời tay/mắt khỏi vị trí an toàn.

Màn hình cảm ứng trên IVI buộc tài xế nhìn và chạm nhiều lần cho một tác vụ đơn giản.

02 · VÀO VÙNG MẤT SÓNG LÀ LÚC CẦN HỎI NHẤT

Hầm, cao tốc đồi, tầng hầm — mạng chập chờn

Trợ lý phụ thuộc cloud sẽ chậm hẳn hoặc im lặng đúng lúc tài xế hỏi đường, hỏi cảnh báo trên đồng hồ, hỏi điểm sạc.

03 · NHIỀU VIỆC CẦN LÀM CÙNG LÚC KHI LÁI

Điều khiển cabin · tra cẩm nang · hỏi thông tin · tìm đường

Mỗi việc hiện đang nằm ở một app/menu khác nhau. Chưa có một điểm vào duy nhất bằng giọng nói.

04 · THAO TÁC SAI CÓ THỂ NGUY HIỂM

Mở cửa khi đang chạy, chỉnh nhiệt vượt giới hạn

Không thể để trợ lý "hiểu đại khái" rồi thao tác thật trên xe. Người lái phải nghe được chính xác lệnh sắp chạy và được xác nhận.

PROBLEM STATEMENT

Tài xế cần một trợ lý dùng bằng giọng nói — rảnh tay, không rời mắt khỏi đường, an toàn khi lái (nghe rõ lệnh sắp chạy, xác nhận với thao tác nhạy cảm, chặn thao tác sai), và không ngắt quãng khi mạng chập chờn.

Rảnh tay — một nút giữ mic, phần còn lại là nghe và nói.

An toàn — mọi thao tác xe đi qua lớp policy tất định, không phải quyết định của model.

Bền với mạng — cloud khi có, tự chuyển local khi không.

GIẢI PHÁP

VIVI gồm ba lớp: nghe, hiểu + lập kế hoạch, thực thi an toàn

LỚP 1 · NGHE VÀ TRẢ LỜI

Giọng nói hai chiều

PhoWhisper / whisper.cpp cho STT · ZeroTTS giọng "Mai Chi" cho TTS. Luồng stream: nói trước, âm thanh về sớm.

LỚP 2 · HIỂU + LẬP KẾ HOẠCH

LangGraph + ModelGateway

Model trả semantic event, không gọi thẳng tool. Cloud (Google) khi có mạng, tự chuyển local khi không — đổi provider giữ nguyên session.

LỚP 3 · THỰC THI AN TOÀN

Policy tất định + HITL

30 tool kiểu typed · policy R0–R3 bằng code · xác nhận một lần cho cửa/kính · verify qua acknowledgement của xe mô phỏng.

- **Đa phương thức:** voice, text và chạm — vào bằng đường nào cũng ra chung một pipeline.
- **Không chết khi mất mạng:** local chạy được một mình; thiếu model vẫn tra cẩm nang bằng SQLite FTS5.
- **Hai vai trò:** Tài xế (ra lệnh, nhận câu trả lời) và Kỹ sư (xem health, trace, audit).
- **Bộ nhớ hội thoại:** short-term theo phiên và long-term khi người dùng yêu cầu rõ.

NĂNG LỰC

Sáu nhóm tool thật, 30 action — tất cả vào bằng giọng nói

ĐIỀU KHIỂN CABIN · 8 TOOL

climate, media, seat, door (open/lock), window, hood, trunk, body.
→ "Đặt nhiệt độ 25 độ" · "Phát nhạc thư giãn" · "Sưởi ghế sau trái mức 2".

DẪN ĐƯỜNG · 9 TOOL

search, plan, select, refine, start, stop, end, cancel, set_gear.
→ "Chỉ đường đi Ninh Bình" · "Sửa điểm đến thành Tràng An" · "Kết thúc dẫn đường".

THÔNG TIN · 3 TOOL

web.search (Tavily), weather.get_forecast, knowledge.lookup.
→ "Thời tiết Hà Nội mai thế nào?" · "Ở Ninh Bình có gì chơi?".

CẨM NANG VF8 · 1 TOOL

manual.search với RAG trên 931 chunk VF8 2026, lọc theo dòng xe + năm.
→ "Đèn vàng hình bình ắc-quy có ý nghĩa gì?".

BỘ NHỚ · 4 TOOL

remember, recall, forget, reset. Chỉ ghi khi người dùng yêu cầu rõ.
→ "Nhớ rằng tôi tên Minh" · "Quên tên tôi".

HỘI THOẠI · 2 TOOL

conversation.respond, conversation.clarify.
Thiếu thông tin → hỏi lại, không đoán.
→ "Mở cửa sổ" → "Bạn muốn cửa sổ bên nào?".

> Luồng khuyên thử trong demo: điều hòa và nhạc (R1 chạy ngay) → mở cửa sổ (R2 chờ "OK" hoặc "hủy") → chuyển sang "đang lái" rồi mở cửa (bị policy chặn) → hỏi cẩm nang → dẫn đường kèm hỏi thông tin điểm đến.

Chi tiết tool trong src/vivi/agents/tools.py — danh sách sinh từ TOOL_REGISTRY

KIẾN TRÚC

Edge gateway + ModelGateway hai tầng cloud–local

IVI — GIAO DIỆN TRÊN XE (CANVAS 3D, VOICE, CẢM ỨNG)

UI Tài xế | Dashboard Kỹ sư | /monitor — health & trace

↓ REST + NDJSON stream

FASTAPI · SRC.VIVI.API.APP:APP

Auth & RBAC | Session / conversation | Telemetry & audit | /api/v2/turn · /api/v2/turn/stream · /api/v1/stt · /api/v1/tts

↓

LANGGRAPH ASSISTANT · MODELGATEWAY

Cloud · Google / OpenAI / OpenRouter

Local · SLM Qwen3-1.7B Q4 trên Jetson | Grammar hồi phục giới hạn

POLICY & HITL · SRC/VIVI/DOMAIN/SAFETY.PY

RISK_BY_INTENT (R0–R3) | Confirmations gắn session + state version

VEHICLE TWIN

MQTT Mosquitto | Memory simulator

RAG VF8

SQLite FTS5 + E5 | 931 chunk

INFORMATION

Tavily · Open-Meteo | Wikipedia · VietMap

Cloud và service online nằm ngoài critical path của điều khiển cabin — rớt mạng vẫn trả lời được

PIPELINE MỘT LƯỢT

7 node LangGraph thật trong src/vivi/graphs/assistant.py

01 **context** → 02 **interpret** → 03 **reducer** → 04 **scheduler** ⇄ 05 **capability** → 06 **response** → 07 **persist**

INTERPRET · NƠI CHỌN CLOUD / LOCAL

Model trả **semantic event**, server validate `SemanticTurn`, sửa JSON lỗi một lần. Google → local → grammar; mỗi tầng có budget riêng.

SCHEDULER ⇄ CAPABILITY

Task sống trong checkpoint. Scheduler chạy tối đa 5 bước tuần tự qua policy; capability trả kết quả, scheduler quyết bước tiếp.

RESPONSE · VERIFY TRƯỚC KHI BÁO

Lệnh xe: đọc ACK MQTT đúng command, đọc state lần nữa, rồi mới nói "đã làm". Mất ACK → "chưa xác minh".

> Mỗi node ghi span timing riêng (có thể xem trong /monitor). Luồng stream `/api/v2/turn/stream` chỉ phát câu trả lời sau khi grounding, safety và verify tương ứng đã hoàn tất — không phát sớm nội dung chưa kiểm chứng.

Đổi provider cloud ↔ local giữa phiên vẫn giữ nguyên session và task đang chờ

TECH STACK

Mọi thành phần đổi được bằng config, không sửa code

THÀNH PHẦN	BIẾN CẤU HÌNH	LỰA CHỌN THỰC TẾ
Runtime	`src.vivi.api.app:app`	FastAPI · Uvicorn · LangGraph 1.2 + checkpoint SQLite · Pydantic v2 · Docker
STT	`stt_provider`	PhoWhisper-medium · whisper.cpp · Soniox · Jetson HTTP · off
LLM / planner	`llm_provider`	Google Gemini Flash Lite · SLM local Qwen3-1.7B Q4 · OpenAI · OpenRouter
TTS	`tts_provider`	ZeroTTS giọng "VIVI/Mai Chi" (local) · VieNeu (cloud) · off
Handbook	`rag_retrieval_mode`	sqlite_local (mặc định) · sqlite · lexical · rank-bm25
Vehicle	`vehicle_provider`	memory · MQTT qua Mosquitto + paho-mqtt
Thông tin	`information_enabled`	Tavily · Open-Meteo · Wikipedia · VietMap
Frontend	—	Vanilla JS + Canvas 3D, reduced-motion, fallback font hệ thống khi offline

> Mặc định **cloud → local → grammar hồi phục**, chỉ tụt tầng khi tầng trước lỗi. `offline_only` / `rag_local_only` chặn mọi HTTP ra ngoài. Khóa API và override theo máy nằm trong `.env`, không commit.

AN TOÀN

Policy R0–R3 là code tất định, không phải prompt

MỨC	INTENT TRONG RISK_BY_INTENT	CHÍNH SÁCH THỰC THI
R0	`vehicle.get_status` · `manual.search` · `conversation.respond/clarify`	Chỉ đọc trạng thái và trả lời — không cần xác nhận.
R1	`climate.set_temperature` · `media.play/pause` · `seat.set_heat_level`	Kiểm role + bounds + live state rồi thực thi ngay.
R2	`window.set_position` · `door.set_lock/open` · `hood/trunk/body.set_open`	Hỏi "nói OK để [action]"; xác nhận một lần, hết hạn 30 giây.
R3	`unsupported.request` · `vehicle.prohibited`	Tool không tồn tại hoặc luôn bị từ chối và ghi audit.

- **Policy đọc live state** ngay trước khi thực thi, không suy ra từ bộ nhớ hội thoại.
- **Confirmation gắn chặt** action + session + state version; đổi tham số là mất hiệu lực.
- **Không có đường đi** từ UI hoặc LLM tới MQTT bỏ qua policy gateway.
- **Nội dung cẩm nang là data**, không phải instruction — chống prompt injection.

Bảng mapping lấy trực tiếp từ src/vivi/domain/safety.py:21–37

GROUNDED RAG

Trả lời cẩm nang VF8 2026 kèm nguồn, thiếu bằng chứng thì abstain

931	E5	12→5	0
chunk + embedding VF8 trong index runtime	multilingual-e5-small INT8, chạy local	retrieval k → final k sau rerank	câu trả lời không có bằng chứng được phát

- **Pipeline chuẩn bị:** crawl → parse → import corpus → prepare embeddings → build index, mọi bước là CLI chạy lại được.
- **Lọc trước khi truy xuất** theo dòng xe, năm sản xuất và locale (VF8 / 2026 / vi_vn).
- **SQLite FTS5 + vector** trong một file; không cần service vector riêng, chạy được offline hoàn toàn.
- **Model chọn mã đoạn bằng chứng** thay vì chép lại trích dẫn; server giữ nguyên đoạn nguồn và gắn link tương ứng.
- **Kiểm số liệu** trong câu trả lời dựa trên các đoạn đã chọn; mâu thuẫn hoặc thiếu bằng chứng ⇒ abstain.
- **Không có model vẫn tra được** handbook bằng SQLite FTS5 và trả trích đoạn có nguồn.

Corpus nguồn và index runtime chia sẻ qua Git; trọng số embedding nằm ngoài Git

BENCHMARK GIỌNG NÓI · JETSON AGX XAVIER · 16–17/10/2026

STT và TTS trên Jetson đạt yêu cầu rảnh tay

109 ms
TTS byte đầu tiên
ZeroTTS FP32 · p95 125 ms

0,80
RTF stream ZeroTTS
<1 là kịp phát

449 ms
STT câu ngắn
Whisper-small xử lý server

32,5%
WER whisper-small
trên giọng tổng hợp

PHƯƠNG ÁN ĐÃ THỬ	KẾT QUẢ ĐO	QUYẾT ĐỊNH
ZeroTTS INT8 TensorRT	RTF 2,56 · load 113 s · RSS 7,18 GiB	Bỏ
ZeroTTS FP32 GPU, stream	RTF 0,80 · TTFA 109 ms	Đang dùng
VieNeu API (cloud)	TTFA 774 ms · CER 6,3% · hạn mức 50k token/ngày	Dự phòng
whisper-base	WER 42,8% · p50 527 ms	Thay
whisper-small	WER 32,5% · p50 821 ms	Đang dùng

Mỗi khâu 1 lượt khởi động rồi lặp 3 lần · p95 nearest-rank, không bỏ lượt lỗi

CÒN YẾU

STT ảo giác trên khoảng lặng dài (7/120 clip thật) — chưa có VAD. WER hiện chỉ đo trên giọng tổng hợp; giọng thật mới có nhãn nháp.

BÀI HỌC

INT8 nhanh gấp đôi trên CPU máy dev nhưng chậm gấp ~3 lần FP32 trên Xavier — **tối ưu phải đo trên đúng phần cứng đích**.

BENCHMARK AGENT · 834 CA LIVE · 18/10/2026 · REV 9F52179

SLM trên Jetson vs Gemini — cùng corpus, cùng oracle

NHÓM TOOL (SỐ CASE)	JETSON VIVI-QWEN3-1.7B	GEMINI 3.5-FLASH-LITE	CHÊNH
Cabin — cửa, kính, nhạc, điều hòa, body (303)	298	301	+3
vehicle_status (144)	129	137	+8
navigation (153)	104	137	**+33**
memory (40)	21	34	**+13**
multi_tool (50)	41	50	+9
information + dialogue + hard + adversarial (144)	126	137	+11
Tổng (834)	**719 · 86,2%**	**796 · 95,4%**	+77

	JETSON	GEMINI
Latency p50	2,3 s	1,2 s
Latency p95	4,2 s	4,7 s
Repair / fallback	13 / 5	4 / 0

CHỒNG LẤN

718 ca cả hai cùng pass · 78 ca chỉ Gemini · 1 ca chỉ Jetson · **37 ca cả hai cùng fail** — ứng viên xem lại oracle.

ĐỌC KẾT QUẢ CÓ ĐIỀU KIỆN

Corpus development, chưa phải holdout review độc lập; test và tool được thiết kế cùng nhau. Mỗi ca 1 lần — chênh vài ca là nhiễu.

20 ca Gemini rơi fallback do timeout/HTTP 503 đã chạy lại (20/20 pass); latency của nhóm này không so trực tiếp

MÃ ĐỀ DEV-01 · NHÓM P-126

Cảm ơn

Rảnh tay bằng giọng nói · an toàn khi lái · không ngắt quãng khi mạng kém.

Ba điều bản demo phải chứng minh — và là ba điều chúng tôi dám để người khác thử phá.

Live demo p126-vivi.onrender.com

Bàn giao Dockerized prototype

Kèm tài liệu kiến trúc

Kèm báo cáo benchmark