MÃ ĐỀ DEV-01 · THE ODYSSEANS (NHÓM P-126) · DEMO DAY COHORT 4

VIVI Cabin Copilot

Trợ lý giọng nói trên xe VinFast — hoạt động được **cả cloud lẫn local offline**, không ngắt khi mất mạng, và không để mô hình ngôn ngữ tự quyết định thao tác trên xe.

Đinh Văn Hùng · trưởng nhóm | Nguyễn Thanh Phong | Nguyễn Minh Dương | Hoàng Trung Khải

🔗 **p126-vivi.onrender.com** · trải nghiệm ngay

PAIN POINT

Lái xe là lúc tài xế khó thao tác nhất

01 · HAI TAY TRÊN VÔ LĂNG, MẮT TRÊN ĐƯỜNG

Mỗi lần với tay chỉnh điều hòa, mở nhạc, tìm điểm đến là một lần rời tay/mắt khỏi vị trí an toàn.

Màn hình cảm ứng trên IVI buộc tài xế nhìn và chạm nhiều lần cho một tác vụ đơn giản.

02 · VÀO VÙNG MẤT MẠNG LÀ LÚC CẦN HỎI NHẤT

Hầm, cao tốc đồi, tầng hầm — mất Internet

Trợ lý phụ thuộc cloud sẽ im lặng đúng lúc tài xế hỏi đường, hỏi cảnh báo trên đồng hồ, hỏi điểm sạc.

03 · NHIỀU VIỆC CẦN LÀM CÙNG LÚC KHI LÁI

Điều khiển cabin · tra cẩm nang · hỏi thông tin · tìm đường

Mỗi việc hiện đang nằm ở một app hoặc menu khác nhau. Chưa có một điểm vào duy nhất bằng giọng nói.

04 · THAO TÁC SAI CÓ THỂ NGUY HIỂM

Mở cửa khi đang chạy, chỉnh nhiệt vượt giới hạn

Không thể để trợ lý "hiểu đại khái" rồi thao tác thật trên xe. Người lái phải nghe được chính xác lệnh sắp chạy và được xác nhận.

Người dùng chính: tài xế xe điện VinFast (mô phỏng)

PROBLEM STATEMENT

Tài xế cần một trợ lý dùng bằng giọng nói — rảnh tay, không rời mắt khỏi đường, an toàn khi lái (nghe rõ lệnh sắp chạy, xác nhận với thao tác nhạy cảm, chặn thao tác sai), và không ngừng hoạt động khi mất mạng.

Rảnh tay — gọi "VIVI" bằng giọng nói hoặc giữ mic; sau đó chỉ nghe và nói, không phải nhìn màn hình.

An toàn — mọi thao tác xe đi qua lớp policy tất định, không phải quyết định của model.

Bền với mạng — có cloud dùng cloud, mất mạng tự chuyển local, mất cả hai vẫn tra được cẩm nang.

TARGET USER · USE CASE

Ba nhóm tình huống thật từ tài xế xe điện

TÌNH HUỐNG 1 · ĐƯỜNG CAO TỐC

Tay bận vô lăng, mắt bận đường

Tài xế cần đổi nhiệt độ, chỉnh nhạc, hỏi đường — nhưng không rời tay/mắt. Mọi tương tác phải **rảnh tay, không nhìn màn hình**.

TÌNH HUỐNG 2 · HẦM CHUNG CƯ, TẦNG HẦM

Mất mạng khi cần hỏi nhất

Vào hầm tìm điểm sạc, hỏi đường ra, kiểm pin — **mất Internet đúng lúc cần nhất**. Trợ lý cloud im lặng, trợ lý local vẫn trả lời.

TÌNH HUỐNG 3 · NHẬN XE MỚI / DÒNG XE LẠ

Không biết nút nào làm gì

"Đèn vàng hình bình ắc-quy là gì?" — tài xế cần tra cẩm nang **có nguồn kiểm chứng**, không phải câu trả lời bịa.

Ba tình huống trên cùng một yêu cầu chung: trợ lý phải rảnh tay, bền với mạng và có bằng chứng khi trả lời cẩm nang.

Nguồn: quan sát hành vi tài xế xe điện + phỏng vấn thử nghiệm nội bộ

GIẢI PHÁP

VIVI gồm ba thành phần làm việc song song

NGHE VÀ TRẢ LỜI

Giọng nói hai chiều

PhoWhisper hoặc whisper.cpp cho STT · ZeroTTS giọng "Mai Chi" cho TTS. Luồng stream: nói trước, âm thanh về sớm.

HIỂU VÀ LẬP KẾ HOẠCH

LangGraph + ModelGateway

Model trả semantic event, không gọi thẳng tool. Cloud (Google) khi có mạng, tự chuyển local khi không — đổi provider giữ nguyên session.

THỰC THI AN TOÀN

Policy tất định + xác nhận một lần

30 tool kiểu typed · bốn mức rủi ro R0–R3 · xác nhận một lần cho cửa và kính · xác minh qua acknowledgement của xe mô phỏng.

- **Vào bằng voice, text hoặc chạm:** cùng một pipeline, cùng một kết quả.
- **Không chết khi mất mạng:** local chạy được một mình; thiếu model vẫn tra cẩm nang bằng SQLite FTS5.
- **Hai vai trò:** Tài xế (ra lệnh, nhận câu trả lời) và Kỹ sư (xem health, trace, audit).
- **Bộ nhớ hội thoại:** short-term theo phiên và long-term khi người dùng yêu cầu rõ.

NĂNG LỰC

Sáu nhóm tool, 30 action — tất cả vào bằng giọng nói

ĐIỀU KHIỂN CABIN · 8 ACTION

Điều hòa · nhạc · sưởi ghế · cửa (mở/khóa) · cửa sổ · capo · cốp · nhiều cửa cùng lúc.
→ "Đặt nhiệt độ 25 độ" · "Phát nhạc thư giãn" · "Sưởi ghế sau trái mức 2".

DẪN ĐƯỜNG · 9 ACTION

Tìm địa điểm · lập tuyến · chọn ứng viên · sửa điểm đến · bắt đầu · dừng · kết thúc · hủy · đổi gear.
→ "Chỉ đường đi Ninh Bình" · "Sửa điểm đến thành Tràng An" · "Kết thúc dẫn đường".

THÔNG TIN · 3 ACTION

Tìm kiếm web (Tavily) · thời tiết (Open-Meteo) · tra kiến thức (Wikipedia).
→ "Thời tiết Hà Nội mai thế nào?" · "Ở Ninh Bình có gì chơi?".

CẨM NANG VF8 · 1 ACTION

RAG trên 931 chunk cẩm nang VF8 2026, lọc theo dòng xe và năm sản xuất.
→ "Đèn vàng hình bình ắc-quy có ý nghĩa gì?".

BỘ NHỚ · 4 ACTION

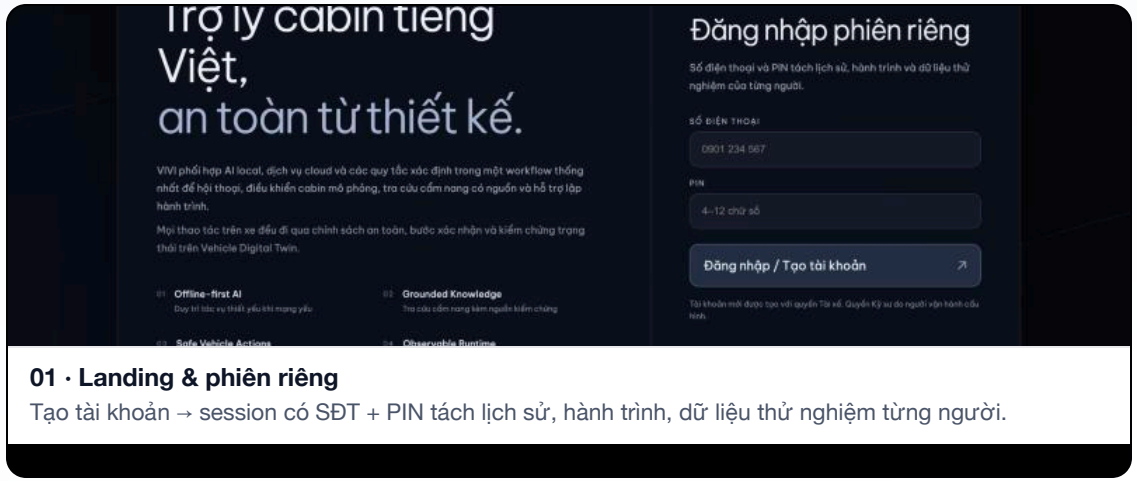
Ghi nhớ · nhắc lại · quên một mục · xóa toàn bộ. Chỉ ghi khi người dùng yêu cầu rõ.
→ "Nhớ rằng tôi tên Minh" · "Quên tên tôi".

HỘI THOẠI · 2 ACTION

Trả lời tự nhiên · hỏi lại khi thiếu thông tin. Không đoán giúp người lái.
→ "Mở cửa sổ" → "Bạn muốn cửa sổ bên nào?".

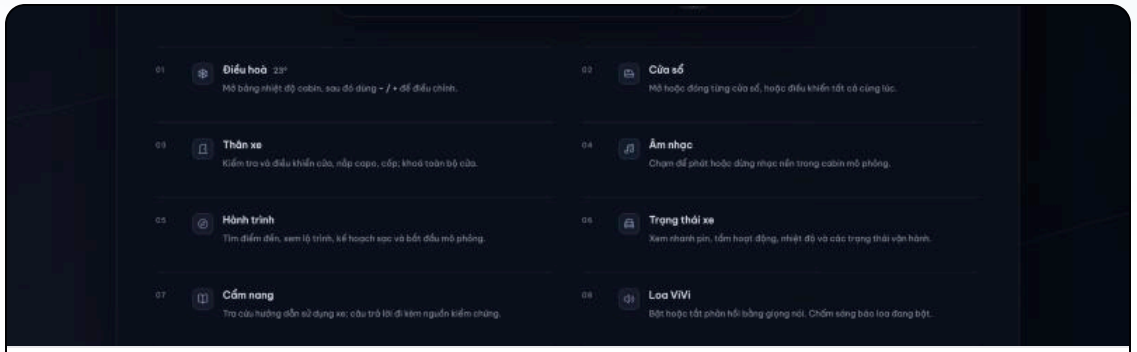
PRODUCT · LIVE DEMO

Giao diện VIVI — 4 màn hình chính



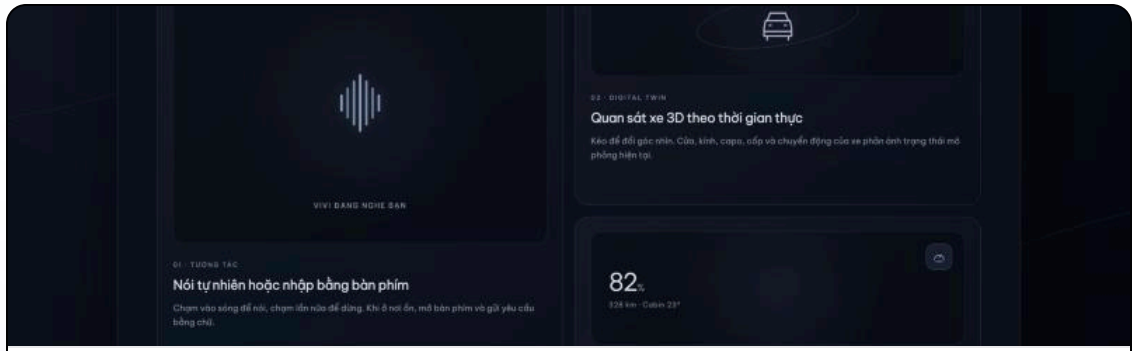
01 · Landing & phiên riêng

Tạo tài khoản → session có SĐT + PIN tách lịch sử, hành trình, dữ liệu thử nghiệm từng người.



02 · 10 tác vụ cabin bằng chạm hoặc giọng

Điều hòa · cửa · nhạc · hành trình · cẩm nang · loa · chế độ P/D · cấu hình — mọi tác vụ đều có voice path.



03 · Voice I/O + Digital Twin 3D + HUD

Nói tự nhiên hoặc chạm; xem xe 3D theo thời gian thực; HUD cảnh báo pin & cabin.



04 · Dẫn đường + cẩm nang + cảnh báo

Tìm đường VietMap, cảnh báo áp suất lốp, kiểm chứng câu trả lời cẩm nang có nguồn.

🔗 Trải nghiệm ngay: **p126-vivi.onrender.com**

KIẾN TRÚC

Một orchestrator trên laptop điều phối Jetson và Cloud

TRUNG TÂM · LUÔN HOẠT ĐỘNG

Laptop / Client

- **UI + input:** text / microphone, hiển thị trạng thái kết nối
- **Session / context:** lịch sử lượt, request ID, trạng thái
- **Orchestrator:** điều phối STT → retrieval → LLM/tools → TTS; kiểm timeout, retry, fallback
- **Retrieval lite:** index và cache local, dùng khi mất Jetson
- **Output:** text + audio tùy yêu cầu

DỊCH VỤ LOCAL QUA LAN

Jetson AGX Xavier

- **Local STT · LLM/SLM · TTS** — model đã cài, chạy offline
- **RAG local** — index và retrieval cẩm nang VF8
- **Local tools** — thiết bị và API nội bộ
- Cung cấp API cho orchestrator trên laptop. Không có orchestrator thứ hai trên Jetson.

DỊCH VỤ ONLINE QUA INTERNET

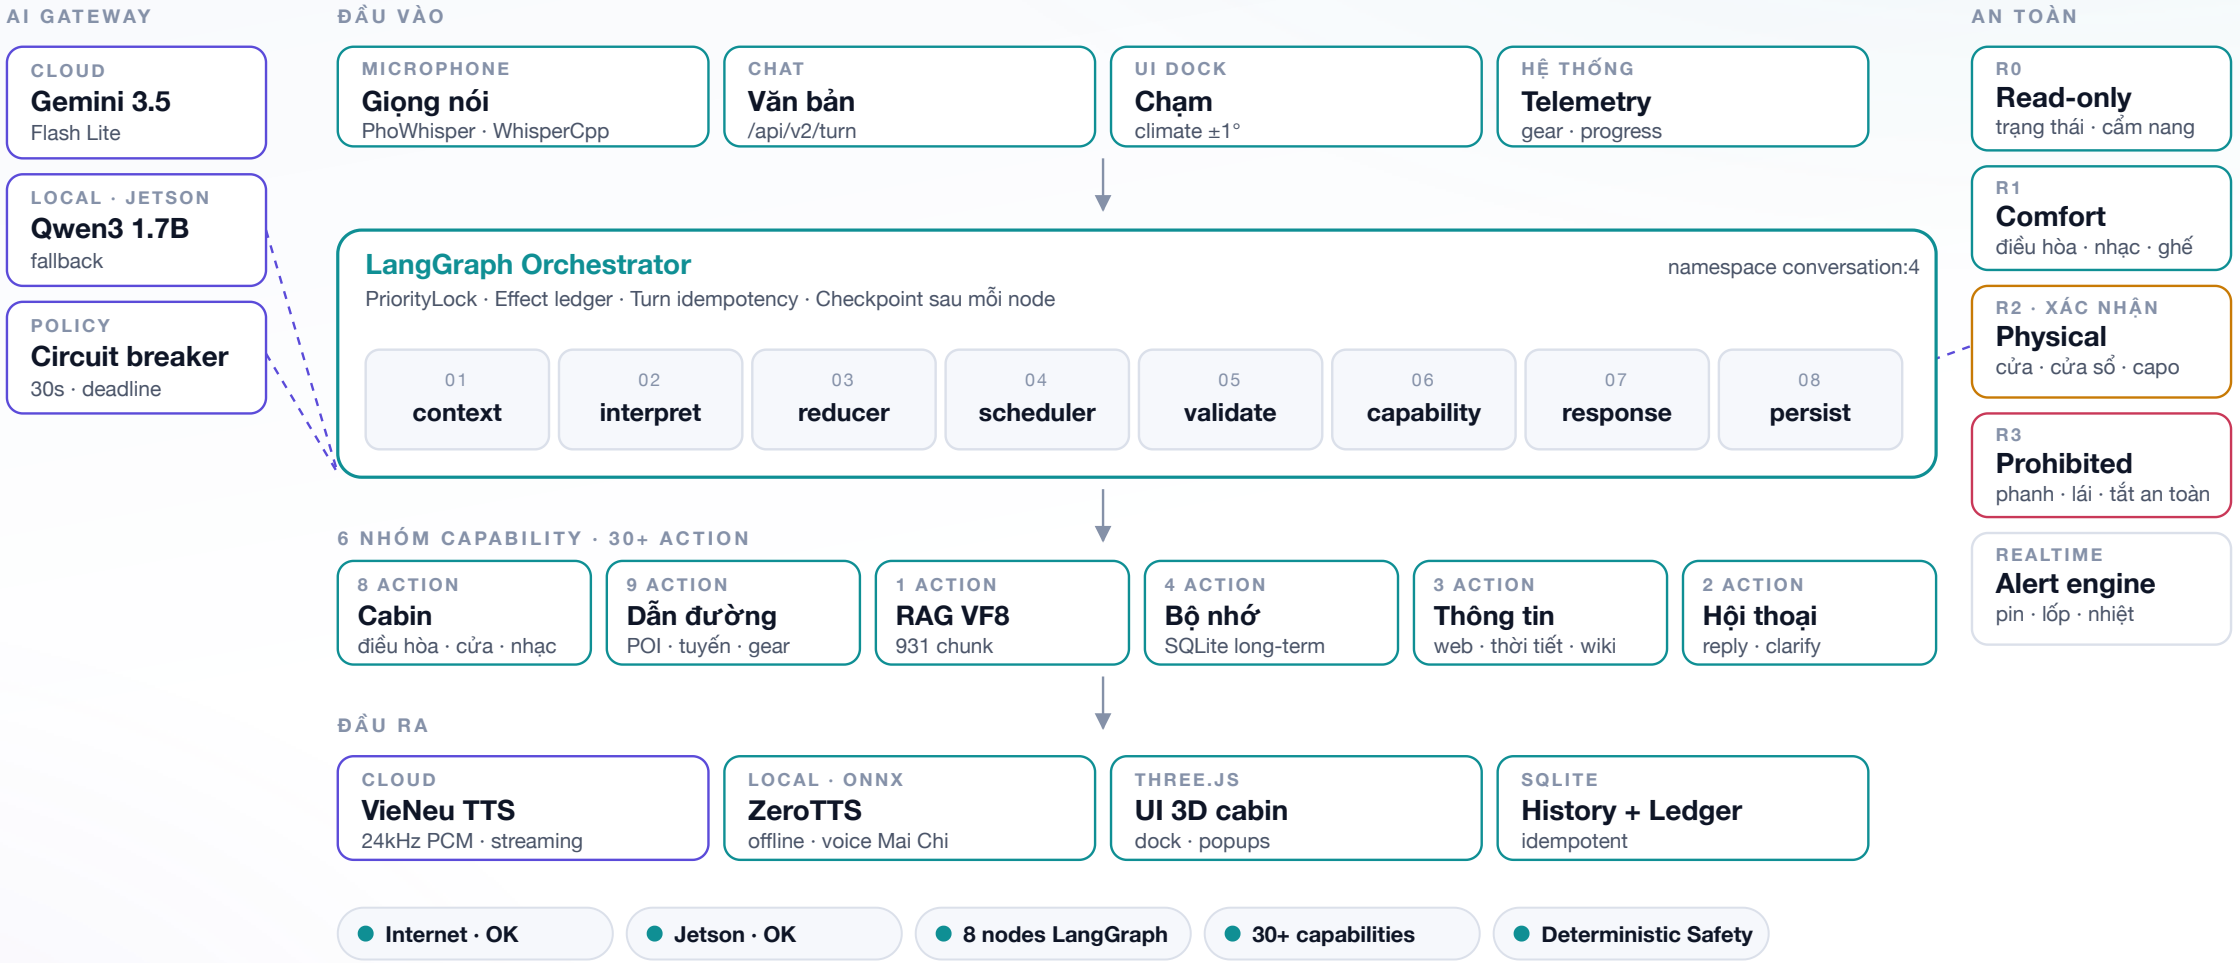
Cloud services

- **Cloud STT · LLM · TTS** — Google · OpenAI · OpenRouter · VieNeu
- **Cloud tools / APIs** — Tavily (web search) · Open-Meteo · Wikipedia · VietMap
- Laptop kết nối Cloud trực tiếp, độc lập với Jetson.

CHẾ ĐỘ KẾT NỐI	JETSON	CLOUD	ORCHESTRATOR CHỌN
1 · Jetson + Internet	✓	✓	Cloud cho STT/LLM/TTS, RAG và tools trên Jetson
2 · Mất Jetson	✗	✓	Cloud STT/LLM/TTS, retrieval lite trên laptop
3 · Mất Internet	✓	✗	Local STT/LLM/TTS và RAG trên Jetson qua LAN

LUỒNG DỰ ÁN

AI Gateway · 8 node LangGraph · 30+ capability · Safety R0–R3



Cloud → local → fallback giới hạn · policy đọc trạng thái xe thật trước mỗi lần thực thi

AN TOÀN

Bốn mức rủi ro — xử lý bằng code, không bằng prompt

MỨC	NHỮNG THAO TÁC THUỘC MỨC NÀY	CÁCH XỬ LÝ
R0	Đọc trạng thái xe · tra cẩm nang · trò chuyện · hỏi làm rõ	Không thay đổi gì trên xe. Trả lời ngay, không cần xác nhận.
R1	Đặt nhiệt độ điều hòa · phát/dừng nhạc · sưởi ghế	Kiểm quyền, kiểm giá trị trong giới hạn, đọc trạng thái xe hiện tại rồi thực thi.
R2	Mở hoặc đóng cửa sổ · khóa hoặc mở khóa cửa · mở capo, cốp	Nói lại chính xác thao tác sắp chạy, chờ "OK" hoặc "hủy". Xác nhận dùng một lần, hết hạn sau 30 giây.
R3	Phanh, lái, tăng tốc · tắt tính năng an toàn · các yêu cầu ngoài phạm vi	Không có công cụ nào thực hiện. Luôn bị từ chối và ghi lại.

- **Policy đọc trạng thái xe thật** ngay trước khi thực thi — không suy luận từ hội thoại.
- **Xác nhận gắn chặt** với thao tác cụ thể, phiên và phiên bản state; đổi tham số là mất hiệu lực.
- **Không có đường đi** nào từ UI hoặc model tới xe mà bỏ qua policy.
- **Nội dung cẩm nang được coi là dữ liệu**, không phải mệnh lệnh — chống prompt injection.

GROUNDED RAG

Trả lời cẩm nang VF8 2026 kèm nguồn, thiếu bằng chứng

931	E5	12→5	0/50
chunk + embedding VF8 trong index runtime	multilingual-e5-small INT8, chạy local	retrieval k → final k sau rerank	câu trả lời không có bằng chứng được phát

- **Pipeline chuẩn bị:** crawl → parse → import corpus → prepare embeddings → build index, mọi bước là CLI chạy lại được.
- **Lọc trước khi truy xuất** theo dòng xe, năm sản xuất và locale (VF8 / 2026 / vi_vn).
- **SQLite FTS5 + vector** trong một file; không cần service vector riêng, chạy được offline hoàn toàn.
- **Model chọn mã đoạn bằng chứng** thay vì chép lại trích dẫn; server giữ nguyên đoạn nguồn và gắn link tương ứng.
- **Kiểm số liệu** trong câu trả lời dựa trên các đoạn đã chọn; mâu thuẫn hoặc thiếu bằng chứng ⇒ abstain.
- **Không có model vẫn tra được** cẩm nang bằng SQLite FTS5 và trả trích đoạn có nguồn.

BENCHMARK GIỌNG NÓI · JETSON AGX XAVIER · 16–17/10/2026

STT và TTS trên Jetson đạt yêu cầu rảnh tay

109 ms
TTS byte đầu tiên
ZeroTTS FP32 · p95 125 ms

0,80
RTF stream ZeroTTS
<1 là kịp phát

449 ms
STT câu ngắn
Whisper-small xử lý server

32,5%
WER whisper-small
trên giọng tổng hợp

PHƯƠNG ÁN ĐÃ THỬ	KẾT QUẢ ĐO	QUYẾT ĐỊNH
ZeroTTS INT8 TensorRT	RTF 2,56 · load 113 s · RSS 7,18 GiB	Bỏ
ZeroTTS FP32 GPU, stream	RTF 0,80 · TTFA 109 ms	Đang dùng
VieNeu API (cloud)	TTFA 774 ms · CER 6,3% · hạn mức 50k token/ngày	Dự phòng
whisper-base	WER 42,8% · p50 527 ms	Thay
whisper-small	WER 32,5% · p50 821 ms	Đang dùng

CÒN YẾU

STT ảo giác trên khoảng lặng dài (7/120 clip thật) — chưa có VAD. WER hiện chỉ đo trên giọng tổng hợp; giọng thật mới có nhãn nháp.

BÀI HỌC

INT8 nhanh gấp đôi trên CPU máy dev nhưng chậm gấp ~3 lần FP32 trên Xavier — **tối ưu phải đo trên đúng phần cứng đích**.

BENCHMARK AGENT · 834 CA LIVE · 18/10/2026

SLM trên Jetson so với Gemini — cùng corpus, cùng oracle

NHÓM TOOL (SỐ CASE)	JETSON VIVI-QWEN3-1.7B	GEMINI 3.5-FLASH-LITE	CHÊNH
Cabin — cửa, kính, nhạc, điều hòa, body (303)	298	301	+3
vehicle_status (144)	129	137	+8
navigation (153)	104	137	**+33**
memory (40)	21	34	**+13**
multi_tool (50)	41	50	+9
information + dialogue + hard + adversarial (144)	126	137	+11
Tổng (834)	**719 · 86,2%**	**796 · 95,4%**	+77

	JETSON	GEMINI
Latency p50	2,3 s	1,2 s
Latency p95	4,2 s	4,7 s
Repair / fallback	13 / 5	4 / 0

CHỒNG LẤN

718 ca cả hai cùng pass · 78 ca chỉ Gemini · 1 ca chỉ Jetson · **37 ca cả hai cùng fail** — ứng viên xem lại oracle.

ĐỌC KẾT QUẢ CÓ ĐIỀU KIỆN

Corpus development, chưa phải holdout review độc lập; test và tool được thiết kế cùng nhau. Mỗi ca 1 lần — chênh vài ca là nhiễu.

CHALLENGES & LEARNINGS

Giới hạn SLM local — bài học quan trọng nhất của dự án

145 ms
SLM thô TTFT
không chậm khi prompt ngắn

0/10
Pipeline strict schema
5 timeout + 5 validation

554→80
Token output giảm
khi nới schema

+505%
TTS TTFA p95 tăng
khi STT+SLM+TTS đồng thời

GIẢ ĐỊNH "CẦN MODEL ≥20B" CHƯA ĐÚNG

Benchmark chứng minh: điểm nghẽn **không phải GPU hay model size**, mà là **contract pipeline 8.000 token quá nặng** với tác vụ 1 câu. Jetson 14,9 GB — model 20B quantized có thể làm latency tệ hơn.

HALLUCINATION "SUBSCRIBE" ≠ LỖI SLM

Phát hiện: câu "hãy subscribe cho kênh..." là **Whisper STT ảo giác trên khoảng lặng/nhiễu**, không phải SLM. Fix bằng VAD + ngưỡng no-speech, không bằng đổi model LLM.

- **Fast-path deterministic** cho lệnh đơn giản ("25 độ", "mở cửa") — SLM chỉ gọi khi mơ hồ.
- **Dynamic tool selection** — câu "điều hòa" chỉ gửi tool climate, không gửi full catalog.
- **Thiết kế lại schema** — chỉ bắt buộc trường cần thiết, native function calling.
- **Dữ liệu đúng miền** — SFT/LoRA với câu lệnh cabin tiếng Việt, hard negative action/handbook.

Rules cho lệnh đơn · SLM cho hiểu ngôn ngữ phạm vi giới hạn · Cloud LLM cho hội thoại phức tạp · Backend luôn giữ quyền kiểm tra, xác nhận, thực thi.

MÃ ĐỀ DEV-01 · THE ODYSSEANS (NHÓM P-126)

Cảm ơn

Rảnh tay bằng giọng nói · an toàn khi lái · không ngừng khi mất mạng.

Ba điều bản demo phải chứng minh — và là ba điều chúng tôi dám để người khác thử phá.

TRẢI NGHIỆM NGAY

🔗 **p126-vivi.onrender.com**

Live 24/7 · không cần cài đặt · tạo session riêng bằng SĐT + PIN.
Full source: **github.com/AI20K-Build-Phase-Cohort-4/P-126**

BÀN GIAO

- Dockerized prototype + Live URL ổn định
- Tài liệu kiến trúc tương tác 4 chế độ mạng
- Bộ eval có phiên bản (`eval/results/`)
- Báo cáo benchmark SLM/STT/TTS + agent 834 ca